



ZAKŁAD SYSTEMÓW ZŁOŻONYCH

Wydział Elektrotechniki i Informatyki

ul. Wincentego Pola 2, 35-959 Rzeszów, tel. 17 865 1340

zsz.prz.edu.pl



**WYDZIAŁ
ELEKTROTECHNIKI
I INFORMATYKI**
POLITECHNIKI RZESZOWSKIEJ

OBRONA PROJEKTU

Rozpoznawanie znaków drogowych

Prowadzący: mgr inż. Patryk Organiściak

Imię i Nazwisko: Eryk Sadowski

Dawid Mizera

Numer albumu : 158848

161885

Rok studiów

IV EF-ZI



Cel projektu

Celem projektu jest stworzenie programu, który będzie potrafił automatycznie rozpoznawać znaki drogowe na podstawie zdjęć lub wideo. Takie rozwiązanie ma bardzo wiele praktycznych zastosowań, np. w systemach bezpieczeństwa drogowego, gdzie możliwość szybkiego i precyzyjnego rozpoznania znaków drogowych może przyczynić się do poprawy bezpieczeństwa na drodze czy też w pojazdach autonomicznych.

Projekt zakłada zastosowanie technologii uczenia maszynowego, w szczególności sieci neuronowych, do nauczania programu rozpoznawania poszczególnych znaków drogowych. Do tego celu wykorzystany został zbiór danych, zawierający różne typy znaków drogowych i ich warianty, a także dane treningowe i testowe.

Opis bazy danych

Baza danych jaka została użyta w projekcie to German Traffic Sign Recognition Benchmark (GTSRB) zawiera ponad 12 tysięcy obrazów przedstawiających różne znaki drogowe z Niemiec. Znaki drogowe są podzielone na 43 klasy, a każdy obraz jest przypisany do jednej z tych klas.

W zbiorze danych znajdują się zarówno proste znaki drogowe, takie jak ograniczenie prędkości, zakaz wjazdu czy nakaz jazdy w prawo, jak i bardziej skomplikowane, np. znaki informujące o przejściu dla pieszych, ograniczeniach prędkości czy też znaki takie jak stop.

Zbiór danych GTSRB jest szeroko stosowany jako benchmark do testowania algorytmów rozpoznawania znaków drogowych, a także do badań nad uczeniem maszynowym i sztuczną inteligencją w dziedzinie rozpoznawania obrazów.



Opis technologii

Podczas tworzenia projektu zostało użyte środowisko PyCharm. Jest to zintegrowane środowisko programistyczne (IDE) stworzone przez JetBrains dla języka Python. Jest to popularne i zaawansowane narzędzie, które oferuje szeroki zakres funkcjonalności, takich jak refaktoryzacja kodu, debugger, system kontroli wersji, wsparcie dla wirtualnych środowisk, narzędzia do testowania kodu oraz wiele innych. PyCharm oferuje również intuicyjny interfejs graficzny użytkownika, umożliwiający łatwe zarządzanie projektem i plikami źródłowymi. Wśród dostępnych funkcji znajdują się również narzędzia do pracy z bazami danych, integracja z narzędziami zewnętrznymi, takimi jak Docker i Vagrant, oraz wsparcie dla innych języków programowania, takich jak HTML, CSS i JavaScript. PyCharm jest kompatybilny z wieloma platformami, w tym Windows, macOS i Linux, co czyni go bardzo uniwersalnym i popularnym wśród programistów Pythona.

Biblioteki użyte w projekcie :

Numpy to biblioteka Pythona służąca do obliczeń naukowych, zwłaszcza operacji na macierzach i tablicach wielowymiarowych.

OpenCV (cv2) to biblioteka do przetwarzania obrazów i wideo, służąca do wykrywania obiektów, analizy obrazów medycznych, rozpoznawania twarzy itp.

Pandas to biblioteka do analizy danych, umożliwiająca łatwą manipulację tabelami i ramkami danych.

Keras to biblioteka służąca do tworzenia i trenowania modeli sieci neuronowych, ułatwiająca implementację algorytmów uczenia maszynowego.

Scikit-learn to biblioteka zawierająca narzędzia do analizy danych i uczenia maszynowego, służąca do klasyfikacji, regresji, grupowania i redukcji wymiarowości danych.



Trenowanie i testowanie modelu

Trenowanie modelu :

Trenowanie modelu , który ma za zadanie rozpoznawać obiekty na zdjęciach. Na początku pliku definiowane są parametry treningowe takie jak liczba epok, wielkość batcha, liczba kroków na epokę oraz wymiary obrazów. Następnie importowane są zdjęcia, ich etykiety oraz definiowane są zbiory treningowe, testowe i walidacyjne. Kod importuje biblioteki takie jak Numpy, CV2, os, Pandas, Matplotlib, Keras i SciKit Learn, a także zawiera instrukcje do przygotowania danych treningowych i budowy modelu sieci neuronowej z warstwami Dense, Conv2D, MaxPooling2D, Dropout i Flatten. Ostatecznie sieć jest trenowana przez określoną liczbę epok, a wynik uczenia (m.in. wartość funkcji straty oraz dokładność) jest wyświetlany na bieżąco w trakcie uczenia.

Testowanie modelu :

Na starcie wczytywany jest model wytrenowany w celu rozpoznawania znaków drogowych na obrazie. Model ten został zapisany w formacie pliku "my_model.h5". Program otwiera połączenie z kamerą i konfiguruje jej parametry takie jak rozmiar klatki, jasność obrazu i próg prawdopodobieństwa. Następnie definiuje funkcje pomocnicze do przetwarzania obrazów - zamiana na skalę szarości, wyrównanie histogramu i normalizacja. Funkcja "getClassName" zwraca nazwę klasy na podstawie numeru klasy przewidzianej przez model. Program w nieskończonej pętli odczytuje obrazy z kamery, przetwarza je i klasyfikuje za pomocą wczytanego modelu. Następnie wypisuje nazwę klasy na obrazie.



Podsumowanie

Projekt rozpoznawania znaków drogowych był ambitnym przedsięwzięciem, które wymagało zastosowania różnorodnych technik i narzędzi, aby uzyskać pozytywne rezultaty. Dzięki wykorzystaniu uczenia maszynowego oraz konwolucyjnych sieci neuronowych udało się stworzyć program, który potrafi rozpoznawać i klasyfikować znaki drogowe na podstawie obrazów. W trakcie pracy nad projektem zastosowano wiele ważnych technik, takich jak preprocessing obrazów, ekstrakcja cech czy normalizacja danych. Dodatkowo, dobór odpowiednich hiper parametrów był kluczowy w osiągnięciu pozytywnych wyników.

Język Python okazał się być świetnym narzędziem do realizacji projektu, dzięki olbrzymiej liczbie bibliotek, które ułatwiają pracę nad tego typu problemami. Podsumowując, projekt rozpoznawania znaków drogowych był udany i przyniósł pozytywne wyniki, co stanowi dowód na to, że Python to doskonały wybór do tworzenia tego typu projektów.